


柴贺样

☎ 18504120288 ✉ heju.chai@gmail.com



教育背景

- 昆士兰大学** 计算机科学 (硕士) 2026.02 - 2027.07
- GPA 6.0/7.0
 - 研究方向：大语言模型微调、检索增强生成、多模态学习
 - 核心课程：高级机器学习、高级算法与数据结构、高维数据处理、研究方法
- 厦门大学** 人工智能 (本科) 2020.09 - 2024.07
- GPA: 3.3/4.0 | 专业排名前 10 名
 - 核心课程：机器学习、深度学习、自然语言处理、计算机视觉、数据结构与算法

实习经历

- 电装(中国)投资有限公司** 算法工程师 2025.11 - 2026.02
- 参与基于 BEVFormer 的多摄像头 BEV 语义分割模型研发：负责核心数据流处理与模型参数调优，针对夜间、雨天等复杂道路场景进行针对性误差分析，使关键目标区域的 mIoU（平均交并比）提升约 4.5%。
 - 基于 DETR 开展驾驶舱行为检测（DMS）模型训练与评估：针对后排严重遮挡、动作类别长尾分布及小目标检测难点，引入 Focal Loss 并优化数据采样策略，使小目标检测 mAP 提升 6.2%，核心异常行为识别准确率达到 93.5%。
 - 负责 Transformer 类车端模型的训练优化与仿真测试：全面引入自动混合精度训练（AMP）与余弦退火学习率调度策略，在不损失模型精度的前提下，降低约 45% 的训练显存占用，并将单次模型迭代周期缩短 30%，大幅提升研发效率。
- 中国邮政集团有限公司鞍山市分公司** 网络安全工程师 2024.07 - 2024.09
- 海量非结构化数据处理与自动化分析：负责日均上千条非结构化系统日志的提取、清洗与特征匹配。编写 Python 自动化脚本排查异常流量与安全隐患，大幅提升初筛效率，积累了扎实的文本数据清洗与自动化处理经验。
 - Linux 环境部署与底层运维：协助处理辖区内 50 余台 Linux 服务器与网络节点的巡检及漏洞修复。保障高并发业务系统的连续性，熟悉分布式节点的底层运维、网络排障与服务器环境配置。

专业技能

- 编程与深度学习**：熟练使用 Python、PyTorch、Hugging Face Transformers，熟悉 Linux、Git、Docker，具备模型训练、调试、评测及推理接口开发经验。
- 大模型微调**：熟悉 Transformer、SFT、LoRA、QLoRA 和 PEFT，具备指令数据构建、微调参数配置、训练监控及微调前后效果对比经验。
- RAG 与知识库**：具备 RAG 系统开发经验，熟悉文档解析、文本分块、Embedding、向量检索、Metadata Filtering、Query Rewrite、Reranker 和答案生成流程。
- Agent 与大模型应用**：熟悉 Qwen、Llama 等开源模型，具备 Prompt Engineering、结构化输出、Function Calling 和 Agent Workflow 开发经验。
- 工程与部署**：熟悉 LangChain、ChromaDB、FastAPI；了解 vLLM、模型量化、推理加速及大模型服务部署流程。

- **计算机视觉：** 具备 DETR、BEVFormer 等 Transformer 视觉模型训练经验，了解图文多模态特征融合和视觉语言模型。

项目经历

Agentic RAG 多模态知识检索系统

2026.03 - 2026.05

- **项目简介：** 面向计算机视觉模型学习与技术文档查询场景，构建支持文本说明、模型架构图和元数据联合检索的多模态知识问答系统。
 - 使用 ChromaDB 构建向量知识库，对技术文档进行清洗、分块、Embedding 和元数据索引，支持按照模型名称、任务类型和网络结构进行过滤检索。
 - 设计 Query Rewrite、查询路由、向量检索、结果重排序和答案生成流程，根据用户问题自动选择文档检索或图片资源检索工具。
 - 通过文本代理描述与 Metadata Linking 建立技术文档和模型架构图之间的关联，实现答案、来源段落与对应架构图的联合返回。
 - 构建包含 **300** 个问题的测试集，使用 Recall@5、MRR、答案正确率和响应延迟评估系统效果；经 Chunk Size、Top-K 和 Reranker 调优后，Recall@5 从 **72.5%** 提升至 **91.8%**。

基于 LoRA 的计算机视觉领域大模型微调

2025.06 - 2025.10

- **项目简介：** 面向计算机视觉专业知识问答任务，对开源大语言模型进行领域指令微调，并比较 Prompt Engineering 与 LoRA 微调效果。
 - 基于 Qwen2.5-3B-Instruct 模型，整理计算机视觉领域指令数据，完成数据清洗、模板构建和训练集、验证集划分。
 - 使用 PEFT 和 LoRA 进行监督微调，配置 Rank、Alpha、Dropout、Target Modules 等参数，并使用混合精度和梯度累积降低显存需求。
 - 从答案正确性、专业术语一致性、结构化输出和幻觉率四个维度，对比 Base Model、Prompt-only 和 LoRA-SFT 模型。
 - LoRA 可训练参数占总参数的 **0.4%**，峰值显存为 **11.5 GB**；微调模型在 **1,500** 条测试集上的准确率由 **68.5%** 提升至 **89.2%**。

多模态内容生成与审核平台

2025.10 - 2026.02

- 设计文本生成模块的 Prompt 模板和结构化输出约束，对生成结果进行敏感词、格式完整性和重复度检查，提高输出稳定性。
- 构建文本与图像联合审核流程，使用 **CLIP (ViT-B/32)** 提取图像视觉特征，结合 **BERT** 提取文本语义特征，对违规内容进行分类和风险评分。
- 针对类别不平衡问题调整采样策略与分类阈值，使核心违规类别的 **F1 分数达到 92.4%**，误检率降低至 **3.5%**。
- 使用 FastAPI 封装模型推理接口，并完成输入校验、异常处理及审核结果返回。

荣誉证书

- 2022 年全国大学生数学建模竞赛，赛区三等奖
- 日语能力测试 JLPT N2
- TOEFL: 93